

**SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I
INFORMACIJSKIH TEHNOLOGIJA OSIJEK**

**Diplomski sveučilišni studij računarstva
Smjer – Umjetna inteligencija i robotika**

Segmentacija stepenica sa slike korištenjem strojnog učenja

Obrada slike i računalni vid

Marina Nedić

Osijek, 2026.

SADRŽAJ

1. UVOD.....	1
2. PREGLED PODRUČJA I PROBLEMATIKE	2
3. PRIKUPLJANJE I OPIS KORIŠTENIH PODATAKA	4
4. TEORIJSKA OSNOVA	7
4.1. Semantička segmentacija	7
4.2. U-Net arhitektura	8
4.3. ResNet arhitektura i prijenosno učenje	9
4.4. DeepLabV3+ arhitektura	10
4.5. Funkcije gubitka i metrike za evaluaciju	10
5. REZULTATI I ANALIZA PODATAKA	12
6. ZAKLJUČAK	18
LITERATURA	20

1. UVOD

Računalni vid bavi se razvojem metoda koje računalima omogućuju interpretaciju vizualnih informacija. U klasičnim problemima klasifikacije slike cilj je odrediti kojoj kategoriji pripada cijela slika, dok je u segmentaciji potrebno odrediti pripadnost svakog piksela. To segmentaciju čini zahtjevnijim, ali informativnijim oblikom analize slike.

U ovom projektu fokus je na stepenicama. Stepence su objekt čiji je oblik čovjeku izrazito prepoznatljiv, unatoč raznim perspektivama, oblicima, materijalima i bojama. Računalu detekcija stepenica može predstavljati problem jer pri treniranju modela moramo uzeti u obzir mjesto gdje se stepenice nalaze, jesu li unutarnje ili vanjske, osvjetljenje koje ovisi o vremenskim uvjetima i dijelu dana, imaju li rukohvat ili ne, nalazi li se čovjek ili nekakva stalna dekoracija (na primjer cvijeće) na njima, perspektiva fotografije, oblik i ostalo. Zato jednostavne metode temeljene na pragu boje ili rubovima nisu dovoljno pouzdane.

Strojno učenje omogućuje učenje složenih značajki iz podataka. Umjesto da se ručno definira kako izgledaju stepenice, model tijekom treniranja uči obrasce iz parova slike i pripadne maske. Ako je maska dobro naučena, ona se može koristiti kao temelj za složenije zadatke poput procjene putanje kretanja.

2. PREGLED PODRUČJA I PROBLEMATIKE

Semantička segmentacija jedno je od važnih područja računalnog vida jer omogućuje klasifikaciju svakog piksela slike u odgovarajuću klasu. Za razliku od obične klasifikacije slike, gdje model određuje samo kojoj klasi pripada cijela slika, semantička segmentacija daje prostorno precizan rezultat u obliku maske. U ovom projektu to znači da se za svaki piksel određuje pripada li klasi stepenice ili klasi pozadina. Takav pristup prikladan je za zadatke u kojima nije dovoljno samo prepoznati postoji li objekt na slici, nego je potrebno znati i gdje se točno nalazi.

Razvoj modernih metoda semantičke segmentacije povezan je s konvolucijskim neuronskim mrežama. Long, Shelhamer i Darrell predstavili su Fully Convolutional Networks, odnosno FCN, kao pristup u kojem se klasične konvolucijske mreže prilagođavaju zadacima predikcije. Umjesto jedne izlazne oznake za cijelu sliku, mreža proizvodi izlaznu mapu koja odgovara prostornoj strukturi ulazne slike [1]. Ova ideja temeljna je za kasnije arhitekture koje se koriste u segmentaciji, uključujući U-Net i DeepLab modele.

Jedna od najpoznatijih arhitektura za semantičku segmentaciju je U-Net. Ronneberger, Fischer i Brox razvili su U-Net za biomedicinsku segmentaciju, ali se arhitektura zbog svoje jednostavnosti i učinkovitosti proširila i na druga područja računalnog vida [2]. U-Net se sastoji od *encodera* koji izvlači značajke i kontekst slike te *decodera* koji vraća prostornu rezoluciju i oblikuje konačnu masku. Posebno važan dio U-Net arhitekture su skip veze, koje povezuju odgovarajuće razine *encodera* i *decodera*. One omogućuju da se pri rekonstrukciji maske koriste i dublje semantičke značajke i ranije prostorne informacije [3].

U-Net je prikladan za segmentaciju stepenica jer stepenice imaju izraženu prostornu strukturu, rubove i ponavljajuće linije. Međutim, osnovni U-Net koji se trenira od početka može biti ograničen ako je skup podataka relativno malen. Zbog toga se često koristi pristup prijenosnog učenja, gdje se *encoder* zamjenjuje mrežom koja je prethodno trenirana na velikom skupu slika. U ovom projektu važnu ulogu ima ResNet34 *encoder*. U kombinaciji s U-Net *decoderom*, ResNet34 omogućuje bolju ekstrakciju vizualnih značajki nego jednostavni *encoder* treniran od nule.

Osim U-Net modela, u području semantičke segmentacije često se koristi i DeepLabV3+. DeepLabV3+ koristi širi kontekst slike i može biti uspješan u segmentacijskim zadacima, posebno

kada je važno obuhvatiti objekte različitih veličina. U ovom projektu DeepLabV3+ se razmatra kao usporedna arhitektura u odnosu na U-Net i ResNet34-U-Net, čime se ispunjava zahtjev usporedbe najmanje dvaju različitih pristupa semantičkoj segmentaciji.

Kod binarne segmentacije važan problem predstavlja neuravnoteženost klasa. U mnogim slikama pozadina zauzima veći dio slike nego objekt koji se segmentira. Ako se model ne prilagodi tom problemu, može postići prividno dobar rezultat tako da favorizira dominantnu klasu. Zato se u segmentacijskim zadacima često koriste funkcije gubitka koje su osjetljivije na preklapanje maski, kao što je *Dice loss*.

Za evaluaciju segmentacijskih modela najčešće se koriste metrike Dice i Intersection over Union, odnosno *IoU*. Dice koeficijent mjeri preklapanje između stvarne i predikcijske maske, dok *IoU* mjeri omjer presjeka i unije tih maski. *IoU* je stroža metrika jer jače kažnjava i prevelike i premale predikcije. Uz ove metrike korisno je promatrati preciznost i odziv jer one pokazuju balans između pogrešno označene pozadine i propuštenih dijelova stepenica.

PyTorch se koristi za izgradnju, treniranje i evaluaciju neuronskih mreža. Biblioteka *segmentation-models-pytorch* pruža gotove implementacije arhitektura kao što su U-Net i DeepLabV3+, s mogućnošću korištenja različitih predtreniranih *encodera* [4]. Za obradu maski i određivanje putanje koristi se OpenCV i funkcije za analizu povezanih komponenti, koje omogućuju izdvajanje najveće povezane regije u binarnoj maski [5].

Nakon što model predvidi masku stepenica, iz te maske moguće je odrediti približnu putanju kretanja. Budući da skup podataka ne sadrži ručno označene početne i krajnje točke putanje, putanja se ne trenira kao zaseban nadzirani model, nego se računa iz predikcijske maske. Time se izlaz iz modela pretvara u praktičnu informaciju - gdje se osoba može kretati po stepenicama i u kojem smjeru.

3. PRIKUPLJANJE I OPIS KORIŠTENIH PODATAKA

Za potrebe ovoga rada korišten je skup podataka od 503 RGB fotografija stepenica [6] namijenjen binarnoj semantičkoj segmentaciji. U skupu podataka nalazile su se i pripadajuće segmentacijske maske, no one nisu korištene u ovom radu, nego su fotografije ponovno anotirane. Svaka ulazna fotografija prikazuje scenu u kojoj se nalaze stepenice, dok pripadajuća maska označava područje fotografije koje pripada stepenicama. Budući da je cilj rada klasifikacija svakog piksela u jednu od dvije klase, maske su binarne - pikseli koji pripadaju stepenicama označeni su bijelom bojom, a pikseli pozadine crnom bojom.

Podaci su organizirani u tri osnovna podskupa: skup za treniranje, skup za validaciju i skup za testiranje. Skup za treniranje koristi se za učenje parametara modela, odnosno za prilagodbu neuronske mreže zadatku segmentacije stepenica. Validacijski skup koristi se tijekom razvoja modela za praćenje kvalitete učenja i odabir najboljeg *checkpointa*. Testni skup koristi se tek nakon treniranja, za završnu procjenu kvalitete modela na slikama koje model nije koristio tijekom učenja.

	split	broj_slika	broj_maski
0	train	352	352
1	validation	75	75
2	test	76	76

Tablica 3.1. Raspodjela podatkovnog skupa

Fotografije u skupu podataka prikazuju stepenice u različitim uvjetima i iz različitih perspektiva. Na nekim fotografijama stepenice zauzimaju velik dio slike, dok su na drugima djelomično zaklonjene ili se nalaze u složenijoj pozadini. Takve razlike čine zadatak zahtjevnijim jer model ne smije učiti samo jednostavne obrasce poput boje ili kontrasta, nego mora prepoznati širu strukturu stepenica. Poseban izazov predstavljaju ograde, podovi, sjene i rubovi koji mogu nalikovati linijama stepenica.

Maske predstavljaju ručno pripremljene oznake stvarnog područja stepenica. One služe kao referentna istina tijekom treniranja i evaluacije modela. U maskama je bijelo područje ono koje model treba naučiti predviđati kao klasu stepenica, dok crno područje predstavlja pozadinu. Cilj je izdvojiti cjelokupno područje stepenica od ostatka slike.

Prije korištenja u modelu fotografije i maske prolaze kroz predobradu. Ulazne slike skaliraju se na veličinu 227 x 227 piksela, što odgovara postavkama korištenima za finalni ResNet34-U-Net model. Maske se također skaliraju na istu veličinu, ali se za njih koristi interpolacija najbližeg susjeda kako bi se sačuvale diskretne vrijednosti klase. Nakon toga se maske binariziraju, odnosno vrijednosti piksela pretvaraju se u 0 za pozadinu i 1 za stepenice.

Za skup za treniranje koriste se augmentacije podataka. Augmentacije uključuju horizontalno okretanje slike, promjenu svjetline i kontrasta te blagu rotaciju i skaliranje. Svrha augmentacije je povećati raznolikost trening skupa bez stvarnog dodavanja novih slika. Time se smanjuje mogućnost da model samo zapamti konkretne primjere iz skupa za treniranje te se postiže bolja generalizacija na nove slike.

Validacijski i testni skup ne koriste augmentacije. To je važno jer se kvaliteta modela mora mjeriti na stvarnim, neizmijenjenim primjerima. Ako bi se augmentacije koristile i tijekom evaluacije, rezultati bi mogli biti manje jasni i teže usporedivi.

Prije treniranja provjerava se jesu li sve potrebne mape prisutne i postoje li ispravni parovi slika i maski. Prikazuje se primjer jedne ulazne slike i pripadajuće stvarne maske. Taj korak omogućuje vizualnu provjeru da se podaci ispravno učitavaju, da maska odgovara slici i da je binarna oznaka pravilno interpretirana.



Slika 3.1. Primjer slike istvarne maske

Ipak, skup podataka ima i određena ograničenja. Model će najbolje raditi na slikama koje su slične onima iz skupa za treniranje. Ako se u stvarnoj primjeni pojave stepenice drugačijeg izgleda, pod drugačijim osvjetljenjem ili iz neuobičajene perspektive, kvaliteta segmentacije može biti slabija. Zbog toga bi se u budućem radu skup podataka mogao proširiti dodatnim slikama, sintetičkim podacima ili preciznijim anotacijama.

Na testnim slikama prikazuju se originalna slika, stvarna maska, predikcija modela i *overlay* prikaz. Takva provjera omogućuje bolju interpretaciju rezultata jer same metrike, poput Dice i IoU vrijednosti mogu davati najbolje rezultate za model koji čovjek ne smatra najboljim.

4. TEORIJSKA OSNOVA

U ovom radu problem segmentacije stepenica promatra se kao zadatak binarne semantičke segmentacije slike. Semantička segmentacija pripada području računalnog vida i dubokog učenja, a cilj joj je svakom pikselu ulazne slike dodijeliti odgovarajuću klasu. U ovom slučaju postoje samo dvije klase: stepenice i pozadina. Za razliku od klasifikacije slike, gdje model daje jednu oznaku za cijelu sliku, segmentacijski model proizvodi prostornu mapu iste ili približno iste strukture kao ulazna slika. Takva mapa omogućuje precizno određivanje područja slike koje pripada objektu od interesa.

Temelj modernih metoda semantičke segmentacije čine konvolucijske neuronske mreže. Konvolucijske neuronske mreže posebno su prikladne za obradu slika jer koriste konvolucijske filtre koji mogu prepoznati lokalne vizualne obrasce, poput rubova, tekstura, prijelaza boja i složenijih oblika. U ranijim slojevima mreža obično uči jednostavnije značajke, dok dublji slojevi uče apstraktnije i semantički bogatije značajke. Kod segmentacije je važno zadržati i semantičke informacije i prostornu preciznost, jer model mora razumjeti što se nalazi na slici, ali i gdje se točno nalazi.

4.1. Semantička segmentacija


Semantička segmentacija može se opisati kao klasifikacija svakog piksela slike. Model uči funkciju koja za svaki piksel slike predviđa pripada li klasi stepenica ili pozadini. U binarnom slučaju izlaz modela može se promatrati kao matrica vjerojatnosti, gdje svaka vrijednost predstavlja vjerojatnost da određeni piksel pripada klasi stepenica.

Nakon što model proizvede izlaznu mapu, najčešće se primjenjuje sigmoid funkcija, kojom se izlazne vrijednosti pretvaraju u raspon od 0 do 1. Zatim se primjenjuje prag, odnosno *threshold*. Ako je vrijednost piksela veća ili jednaka odabranom pragu, piksel se klasificira kao stepenica. Ako je manja od praga, piksel se klasificira kao pozadina. Time se dobiva binarna maska.

U ovom projektu segmentacija je važna jer ne daje samo informaciju o tome postoje li stepenice na slici, nego i točno određuje njihovo područje. Takav rezultat omogućuje daljnju obradu, primjerice određivanje preporučene putanje kretanja po stepenicama.

4.2. U-Net arhitektura

U-Net je jedna od najpoznatijih arhitektura za semantičku segmentaciju. Izvorno je razvijena za biomedicinsku segmentaciju, ali se zbog svoje učinkovitosti često koristi i u drugim segmentacijskim zadacima. U-Net ima oblik slova U, po čemu je i dobio naziv. Sastoji se od dva glavna dijela: *encodera* i *decodera*.



Slika 4.2. Opći prikaz U-Net arhitekture


Zadatak enkodera je postupno smanjivati prostornu rezoluciju slike i izdvajati sve složenije značajke. U tom dijelu mreže koriste se konvolucijski slojevi, aktivacijske funkcije i operacije smanjivanja rezolucije. Kako se ide dublje kroz *encoder*, prostorna dimenzija značajki se smanjuje, ali se povećava broj kanala i razina apstrakcije.

Zadatak dekodera je vratiti prostornu rezoluciju i iz naučenih značajki rekonstruirati segmentacijsku masku. Dekoder koristi operacije povećanja rezolucije, odnosno upsampling, te konvolucijske slojeve kojima se postupno oblikuje konačna maska. Važan dio U-Net arhitekture su skip veze koje povezuju odgovarajuće razine *encodera* i *decodera*, čime *decoder* može koristiti ranije prostorne informacije koje bi se inače izgubile tijekom smanjivanja rezolucije.

4.3. ResNet arhitektura i prijenosno učenje

ResNet arhitektura uvedena je kako bi se olakšalo treniranje dubljih neuronskih mreža. Glavna ideja ResNeta su rezidualne veze, koje omogućuju lakši protok informacija i gradijenata kroz mrežu [7]. Umjesto da svaki sloj mora izravno naučiti potpunu transformaciju ulaza, rezidualni blokovi uče razliku između ulaza i željenog izlaza. Takav pristup smanjuje problem nestajućih gradijenata i omogućuje stabilnije treniranje dubljih modela.

U ovom projektu koristi se ResNet34-U-Net model. To znači da se ResNet34 koristi kao enkoder, dok se dekodek koristi za rekonstrukciju segmentacijske maske. Prednost takvog pristupa je u tome što ResNet34 može biti predtreniran na velikom skupu podataka, primjerice ImageNetu. Takvo predtreniranje omogućuje modelu da već na početku ima naučene korisne vizualne značajke, kao što su rubovi, teksture i osnovni oblici.




Slika 4.3. ResNet34-U-Net arhitektura [8]

Prijenosno učenje posebno je korisno kada skup podataka za konkretan zadatak nije jako velik. Umjesto da model sve uči od početka, koristi se znanje naučeno na većem i općenitijem skupu slika. Zatim se model dodatno prilagođava specifičnom zadatku, u ovom slučaju segmentaciji stepenica. Zbog toga ResNet34-U-Net može postići bolje rezultate od jednostavnijeg U-Net modela koji nema predtrenirani *encoder*.

4.4. DeepLabV3+ arhitektura

DeepLabV3+ arhitektura je također prikladna za semantičku segmentaciju. DeepLabV3+ model može koristiti širi kontekst slike, a da pritom ne izgubi previše prostornih detalja. ASPP, odnosno Atrous Spatial Pyramid Pooling koristi više konvolucija s različitim stopama dilatacije, čime model može analizirati sliku na više prostornih mjerila. To je korisno kada objekt može imati različite veličine ili kada je potrebno razumjeti širi kontekst scene. DeepLabV3+ dodatno koristi *decoder* dio kako bi se poboljšala lokalizacija i preciznost granica objekata [9].



Slika 4.4. DeepLabV3+ arhitektura

U ovom radu DeepLabV3+ koristi se kao usporedna arhitektura u odnosu na U-Net i ResNet34-U-Net. Time se omogućuje analiza različitih pristupa semantičkoj segmentaciji. Iako DeepLabV3+ može biti vrlo snažan model, konačan izbor modela ne ovisi samo o teorijskoj složenosti arhitekture, nego i o stvarnim rezultatima, vizualnoj kvaliteti maski i stabilnosti predikcija.

4.5. Funkcije gubitka i metrike za evaluaciju

Tijekom treniranja modela potrebno je definirati funkciju gubitka, odnosno *loss* funkciju. Funkcija gubitka mjeri razliku između predikcije modela i stvarne maske. Cilj treniranja je minimizirati tu pogrešku. Kod binarne segmentacije često se koristi Binary Cross Entropy *loss*, koji uspoređuje predviđenu vjerojatnost svakog piksela sa stvarnom oznakom. Kod segmentacije može

postojati problem neravnoteže klasa. Pozadina često zauzima veći dio slike nego objekt interesa, pa model može biti pristran prema dominantnoj klasi. Zato se koriste i funkcije gubitka temeljene na preklapanju maski, kao što je Dice loss koji je povezan s Dice koeficijentom i potiče model da poveća preklapanje između predikcijske i stvarne maske.

Dice koeficijent računa se prema izrazu:

$$\text{Dice} = 2 * |A \cap B| / (|A| + |B|),$$

gdje je A stvarna maska, a B prediktirana maska. Vrijednost Dice koeficijenta kreće se od 0 do 1. Vrijednost 1 označava savršeno preklapanje, dok vrijednost 0 znači da nema preklapanja između maski.

IoU, odnosno Intersection over Union, računa se prema izrazu:

$$\text{IoU} = |A \cap B| / |A \cup B|$$

IoU je stroža metrika jer u nazivniku koristi uniju stvarne i prediktirane maske. Ako model predvidi preveliku masku ili propusti velik dio stvarne maske, IoU se smanjuje.

Uz Dice i IoU, mogu se koristiti preciznost i odziv. Visoka preciznost znači da model ne označava previše pozadine kao stepenice, dok visok odziv znači da model ne propušta velik dio stepenica.

5. REZULTATI I ANALIZA PODATAKA

U ovom poglavlju prikazani su rezultati dobiveni treniranjem i evaluacijom modela. Rezultati se analiziraju kroz metrike, vizualnu usporedbu predikcijskih maski sa stvarnim maskama te kroz primjenu segmentacijske maske za određivanje preporučene putanje kretanja po stepenicama.

Cilj evaluacije nije bio dobiti isključivo što veće numeričke vrijednosti metrika, nego i provjeriti daje li model vizualno smislene maske. To je važno jer dvije maske mogu imati slične vrijednosti Dice ili IoU metrike, ali se vizualno mogu značajno razlikovati.

Neke slike sadrže jasne i pravilne stepenice, dok druge sadrže sjene, ograde, podove ili druge elemente koji mogu otežati segmentaciju. Poseban problem predstavljaju područja koja vizualno nalikuju stepenicama, primjerice linije na podu, rubovi ograde, snijeg ili pijesak. Takvi elementi mogu dovesti do pogrešaka, odnosno do toga da model dio pozadine pogrešno označi kao stepenice i obrnuto.

Prije treniranja slike su skalirane na veličinu 227 x 227 piksela te je korištena ImageNet normalizacija jer finalni model koristi ResNet34 *encoder* s predtreniranim težinama. Na trening skupu korištene su augmentacije, kao što su horizontalno okretanje, promjena svjetline i kontrasta te blage geometrijske transformacije. Time se povećala raznolikost podataka i smanjila mogućnost da model samo zapamti slike iz trening skupa.

U projektu je razmatrano više modela. Prvi model bio je početni U-Net, koji služi kao *baseline*. Drugi model bio je ResNet34-U-Net, koji koristi predtrenirani ResNet34 *encoder*. Treći model (usporedni ResNet34-U-Net) bio je slične ResNet34-U-Net arhitekture koji se trenirao kao pokušaj da se najbolji ResNet34-U-Net poboljša, međutim treniranje nije dalo bolje rezultate. Osim toga, analizirani su i DeepLabV3+ modeli kao dodatna arhitekturna usporedba.

	id	label	test_loss	test_dice	test_iou	test_precision	test_recall
0	model U-Net	Početni U-Net	0.358931	0.707267	0.593303	0.711101	0.783582
1	ResNet34 U-Net BEST	Najbolji model: ResNet34 U-Net	0.176210	0.871279	0.793305	0.861065	0.910899
2	ResNet34 U-Net	Usporedni ResNet34 U-Net	0.183215	0.864094	0.783215	0.871826	0.884184
3	DeepLabV3+ ResNet34	dulji retraining	0.220020	0.847574	0.767719	-	-

Tablica 5.1. Usporedba modela

Tablica 5.1. prikazuje usporedbu četiri modela za binarnu semantičku segmentaciju stepenica. Modeli su uspoređeni prema vrijednostima *test_loss*, *test_dice*, *test_iou*, *test_precision* i *test_recall*. Ove metrike zajedno pokazuju koliko dobro model predviđa područje stepenica na testnom skupu.

Najbolji ukupni rezultat postiže model ResNet34 U-Net BEST, odnosno model za koji je odlučeno da je najbolji. On ima najmanji *test_loss*, koji iznosi 0.176210, te najviše vrijednosti glavnih segmentacijskih metrika: *test_dice* = 0.871279 i *test_iou* = 0.793305. Dice koeficijent pokazuje stupanj preklapanja predikcijske i stvarne maske. Budući da ovaj model ima najveće vrijednosti obje metrike, može se zaključiti da najbolje segmentira područje stepenica.


Početni U-Net model ostvaruje znatno slabije rezultate. Njegov *test_loss* iznosi 0.358931, što je najviša vrijednost pogreške u tablici. Također ima najniže vrijednosti Dice i IoU metrika: *test_dice* = 0.707267 i *test_iou* = 0.593303. To pokazuje da osnovni U-Net može naučiti zadatak, ali ne postiže dovoljno precizne maske u usporedbi s modelima koji koriste ResNet34 *encoder*. Očekivano je da će početni U-Neta dati slabije rezultate jer taj model nema predtrenirani *encoder* i sve značajke uči isključivo iz dostupnog skupa podataka.

Usporedni ResNet34 U-Net postiže vrlo dobre rezultate, ali ipak nešto slabije od najboljeg modela. Njegov *test_loss* iznosi 0.183215, *test_dice* = 0.864094, a *test_iou* = 0.783215. Ove vrijednosti su blizu najboljeg modela, što pokazuje da je ResNet34-U-Net arhitektura općenito vrlo prikladna za ovaj zadatak. Ipak, najbolji model ima nešto niži *loss*, veći Dice i veći IoU, pa je zbog toga odabran kao završni model. Usporedni ResNet34 U-Net ima nešto veći *test_precision* = 0.871826 od najboljeg modela, čiji preciznost iznosi 0.861065. To znači da usporedni model nešto rjeđe označava pozadinu kao stepenice. Međutim, njegov odziv je niži (0.884184) u odnosu na najbolji model (0.910899), što znači da propušta veći dio stvarnih piksela stepenica.

DeepLabV3+ ResNet34 postiže $test_loss = 0.220020$, $test_dice = 0.847574$ i $test_iou = 0.767719$. Prema $loss$, Dice i IoU vrijednostima može se zaključiti da je njegova ukupna segmentacijska kvaliteta nešto slabija od ResNet34 U-Net modela. To pokazuje da DeepLabV3+ može uspješno naučiti segmentaciju stepenica, ali u ovom projektu nije nadmašio ResNet34-U-Net pristup.


Može se zaključiti da su modeli s predtreniranim *encoderima* znatno bolji od početnog U-Net modela.

Slika 5.1. prikazuje vizualnu evaluaciju finalnog ResNet34 U-Net BEST modela (modela za koji je odlučeno da je najbolji) na testnom skupu. Prvi prikaz je originalna slika, drugi prikaz je stvarna, ručno označena, maska, treći prikaz je predikcijska maska modela pri $threshold$ vrijednosti 0.50, a četvrti prikaz je *overlay* predikcije preko originalne slike. *Overlay* prikazuje masku u crvenoj boji preko slike stepenica kako bi lakše procijenili kvalitetu predikcijske maske, dok $threshold$ određuje kolika je potrebna vjerojatnost da je piksel stepenica kako bi se označio kao stepenica (označeno sa $t=50$, dakle vjerojatnost mora biti $\geq 50\%$). Ovakav prikaz koristan je iz razloga što isključivo numeričkom evaluacijom modela ne možemo odrediti stvarnu kvalitetu modela. Iz slike se može primjetiti kako za osnovni oblik stepenica model nema problema pri pronalasku stepenica, ali kada su stepenice zakrivljenog, odnosno stiliziranog oblika, model ne može u potpunosti odrediti područje stepenica.




Slika 5.1 Rezultati modela koji za koji je procijenjeno da je najbolji

Slika 5.2. prikazuje usporedbu U-Net *baseline* modela, ResNet34 U-Net i najboljeg ResNet34 U-Net *BEST* modela. *Baseline* model često stvarne stepenice ne označi kao stepenice, a pozadinu označi kao stepenice. ResNet34 U-Net i ResNet34 U-Net *BEST* model daju slične rezultate, ali *BEST* model je malo precizniji.



Slika 5.2. Rezultati usporedbe U-Net *baseline* modela, ResNet34 U-Net i ResNet34 U-Net *BEST* modela

Slika 5.3. prikazuje koliko dobro DeepLabV3+ model označava stepenice. Prikazane su originalna testna slika, stvarna maska, predikcijska maska modela pri *threshold* vrijednosti 0.50 i *overlay* prikaz. Iako model prepoznaje dio strukture stepenica, predikcija sadrži značajne pogreške, osobito za stepenice nepravilnog oblika. Na *overlay* prikazu vidi se da model velik dio pozadine, posebno područje pijeska, pogrešno označava kao stepenice. Zbog takvih *false positive* područja DeepLabV3+ model nije odabran kao najbolji model, nego služi kao usporedna arhitektura u analizi.



Slika 5.3. Prikaz DeepLabV3+ modela


Slika 5.4. prikazuje određivanje preporučene putanje kretanja po stepenicama na temelju najboljeg odabranog modela, odnosno ResNet34 U-Net *BEST modela*. Nakon što model odredi masku stepenica, nad njom se provodi dodatna obrada kojom se izračunava približna putanja kretanja.

Slika sadrži prikaz testne slike, stvarne maske, maske koju je odredio model te prikaz testne s predikcijskom *overlay* maskom i predloženom putanjom i smjerom kretanja. Plava točka označava početnu točku putanje, dok žuta točka označava krajnju točku. Budući da je u kodu smjer postavljen prema gore (engl. *up*), putanja se računa od donjeg dijela maske prema gornjem dijelu maske te sustav pretpostavlja kretanje prema gore po stepenicama.

U implementaciji se koristi funkcija koja najprije pronalazi najveću povezanu komponentu u predikcijskoj maski jer model ponekad može pogrešno označiti male odvojene dijelove slike kao stepenice. Takva manja područja mogu nastati zbog šuma ili pogrešne predikcije. Nakon izdvajanja

glavne komponente računa se središnja linija maske tako što se za svaki red slike pronalaze pikseli koji pripadaju maski stepenica te se računa sredina između lijevog i desnog ruba tog područja. Tako se za svaki relevantni red dobiva jedna središnja točka. Niz tih točaka čini središnju liniju stepenica, odnosno putanju koja prolazi kroz sredinu maske. Početna i krajnja točka se određuju iz donjeg i gornjeg dijela izračunate središnje linije.

Važno je naglasiti da model u ovom projektu ne predviđa putanju izravno. On ne daje kao izlaz koordinate početne i krajnje točke, niti samostalno određuje smjer kretanja. Izravni izlaz modela je segmentacijska maska stepenica. Putanja se zatim računa naknadno, korištenjem jednostavnih postupaka obrade slike nad prediktiranom maskom. To je opravdan pristup jer korišteni skup podataka sadrži slike i segmentacijske maske, ali ne sadrži ručno označene putanje kretanja. Bez takvih oznaka ne bi bilo moguće nadzirano trenirati model koji izravno predviđa početnu i krajnju točku.



Slika 5.4. Procjena putanje i smjera kretanja prema perspektivi fotografije

6. ZAKLJUČAK

U ovom radu cilj zadatka bio je klasificirati svaki piksel ulazne slike u jednu od dvije klase: stepenice ili pozadina. Time se problem nije promatrao samo kao prepoznavanje postojanja stepenica na slici, nego kao precizno određivanje njihova prostornog područja. Takav pristup omogućuje detaljniju analizu scene i predstavlja temelj za dodatne postupke, poput određivanja preporučene putanje kretanja.

U radu je implementirano i analizirano više modela. Početni U-Net korišten je kao *baseline* model, odnosno početna točka za usporedbu. Iako je ovaj model pokazao da može naučiti osnovni oblik zadatka, njegovi rezultati bili su slabiji u odnosu na modele s predtreniranim enkoderom. Poboljšani ResNet34-U-Net pokazao se znatno uspješnijim jer kombinira prednosti U-Net arhitekture i ResNet34 *encodera* s ImageNet predtreniranjem. Time model dobiva snažnije vizualne značajke i bolju sposobnost generalizacije.

Kao dodatna arhitektura analiziran je DeepLabV3+. Time je omogućena usporedba različitih pristupa semantičkoj segmentaciji. DeepLabV3+ koristi atrous konvolucije i širi kontekst slike, ali u ovom projektu nije pokazao dovoljno stabilne vizualne rezultate da bi zamijenio ResNet34-U-Net. Ovaj dio rada pokazuje da složenija arhitektura ne mora nužno biti najbolji izbor za svaki konkretan skup podataka. Konačan odabir modela treba se temeljiti na kombinaciji metrika, vizualne kvalitete maski i praktične primjenjivosti.

Model će najbolje raditi na slikama koje su slične onima korištenima tijekom treniranja. U stvarnim uvjetima mogu se pojaviti drugačiji tipovi stepenica, promjenjivo osvjetljenje, sjene, refleksije ili složene pozadine, što može smanjiti kvalitetu segmentacije. Drugo ograničenje odnosi se na činjenicu da se putanja računa iz maske, pa njezina točnost izravno ovisi o kvaliteti segmentacije. Ako je maska netočna, i putanja može biti pogrešno određena. U budućem radu bilo bi korisno proširiti skup podataka dodatnim slikama stepenica iz različitih okruženja i perspektiva. Također bi bilo korisno dodati ručne anotacije putanje, odnosno početne i krajnje točke kretanja. Time bi se mogao trenirati zaseban model ili dodatna grana postojeće mreže koja bi izravno predviđala putanju.

Kao završni model odabran je ResNet34-U-Net jer daje najstabilnije i najpouzdanije rezultate. Time je pokazano da kombinacija strojnog učenja i klasične obrade slike može uspješno riješiti problem segmentacije stepenica i poslužiti kao temelj za daljnje sustave prostorne interpretacije i asistivne navigacije.

LITERATURA

- [1] Jonathan Long, Evan Shelhamer, Trevor Darrell, „Fully Convolutional Networks for Semantic Segmentation“, UC Berkeley, 2015. <https://arxiv.org/pdf/1411.4038> (posljednje pristupljeno: 26.6.2026.)
- [2] Olaf Ronneberger, Philipp Fischer, Thomas Brox „U-Net: Convolutional Networks for Biomedical Image Segmentation“, Computer Science Department and BIOS Centre for Biological Signalling Studies, University of Freiburg, Germany, 2015. <https://arxiv.org/pdf/1505.04597> (posljednje pristupljeno: 26.6.2026.)
- [3] Wang Jiangtao, Nur Intan Raihana Ruhaiyem, Fu Panpan, „A Comprehensive Review of U-Net and Its Variants: Advances and Applications in Medical Image Segmentation“, School of Computer Sciences, Universiti Sains Malaysia, Penang, Malaysia, School of Network Communication, Zhejiang Yuexiu University, Shaoxing, China, 2025. <https://arxiv.org/pdf/2502.06895> (posljednje pristupljeno: 3.7.2026.)
- [4] Segmentation Models’s documentation, <https://smp.readthedocs.io/en/latest/models.html> (posljednje pristupljeno: 26.6.2026.)
- [5] OpenCV, https://docs.opencv.org/4.13.0/d3/dc0/group_imgproc_shape.html (posljednje pristupljeno: 26.6.2026.)
- [6] Ashwini Gaikwad, Vinaya Gohokar, Rupali Kute, „Staircase Dataset“, 2023. <https://data.mendeley.com/datasets/7m97gp4yz9/2> (posljednje pristupljeno: 26.6.2026.)
- [7] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun, „Deep Residual Learning for Image Recognition“, Microsoft Research, 2015 <https://arxiv.org/pdf/1512.03385> (posljednje pristupljeno: 3.7.2026.)
- [8] Edwin Salcedo, Mona Jaber, Jesús Carrión, „A Novel Road Maintenance Prioritisation System Based on Computer Vision and Crowdsourced Reporting“, Journal of Sensor and Actuator Networks, 2022. https://www.researchgate.net/figure/Resnet34-UNet-final-architecture-implemented-with-PyTorch-for-road-segmentation_fig4_358614333 (posljednje pristupljeno: 3.7.2026.)

[9] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam, „Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation“, Google Inc., 2018. <https://arxiv.org/pdf/1802.02611> (posljednje pristupljeno: 4.7.2026.)